

BÀI THỰC HÀNH SỐ 3

I. Mục tiêu

Sau khi hoàn thành bài Lab, sinh viên có thể:

1. Kiến thức

1. Hiểu bài toán phân lớp dữ liệu và mục tiêu dự đoán nhãn từ dữ liệu đầu vào
2. Nắm được các phương pháp đánh giá mô hình phân lớp như: Accuracy, Precision, Recall, F1-score
3. Hiểu nguyên lý hoạt động của các thuật toán: Cây quyết định (Decision Tree): phân nhánh dữ liệu dựa trên tiêu chí như Gini hoặc Entropy
4. Hiểu nguyên lý hoạt động của các thuật toán: Naive Bayes: mô hình xác suất dựa trên định lý Bayes và giả định độc lập giữa các thuộc tính

2. Kỹ năng

- Xây dựng mô hình phân lớp từ dữ liệu
- Huấn luyện và dự đoán bằng các thuật toán Decision Tree và Naive Bayes
- Đánh giá và so sánh hiệu quả mô hình bằng các chỉ số
- Phân tích kết quả và lựa chọn mô hình phù hợp cho bài toán

II. Tóm tắt lý thuyết

Phân lớp là một bài toán trong khai phá dữ liệu và học máy, trong đó mục tiêu là xây dựng một mô hình có khả năng gán một đối tượng vào một lớp xác định dựa trên các đặc trưng của đối tượng đó.

Trong bài toán phân lớp, mỗi mẫu có:

- Các thuộc tính đầu vào hay còn gọi là đặc trưng.
- Một nhãn lớp biểu thị mẫu đó thuộc loại nào.

Từ dữ liệu đã biết nhãn, ta huấn luyện một mô hình để khi gặp dữ liệu mới chưa biết nhãn, mô hình có thể dự đoán đúng lớp của nó.

Về bản chất, phân lớp là bài toán học một hàm ánh xạ:

$$f(X) = y$$

trong đó:

- X là tập thuộc tính đầu vào,
- y là nhãn lớp đầu ra.

Điểm quan trọng là mô hình không chỉ học thuộc dữ liệu huấn luyện, mà phải khái quát hóa tốt. Nghĩa là khi gặp dữ liệu mới, mô hình vẫn dự đoán đúng với tỷ lệ cao.

1. Các loại bài toán phân lớp

Phân lớp nhị phân

Chỉ có hai lớp.




Ví dụ:

- Có bệnh / Không có bệnh
- Kết quả đạt / Kết quả không đạt
- Email spam / Không spam

Phân lớp đa lớp

Có nhiều hơn hai lớp.




Ví dụ:

- Phân loại loài hoa: hoa hồng, hoa cúc, hoa lan
- Phân loại chữ số viết tay: 0, 1, 2, ..., 9

Phân lớp đa nhãn

Một mẫu có thể thuộc nhiều lớp cùng lúc. Ví dụ: Một bức ảnh có thể chứa cả người, xe hơi, và cây.

Multi-Class		Multi-Label	
C = 3	Samples	Samples	
	  	  	
	Labels (t) [0 0 1] [1 0 0] [0 1 0]	Labels (t) [1 0 1] [0 1 0] [1 1 1]	

2. Đánh giá bài toán phân lớp:

Trong bài toán phân lớp, sau khi xây dựng mô hình, ta cần đánh giá xem mô hình dự đoán tốt đến đâu trên dữ liệu. Để làm được điều này, dữ liệu thường được chia thành tập huấn luyện và tập kiểm tra.

Tập huấn luyện

Tập huấn luyện là tập dữ liệu được dùng để mô hình học ra quy luật từ dữ liệu đầu vào và nhãn đầu ra. Trong giai đoạn này, mô hình sẽ sử dụng các mẫu đã biết nhãn để điều chỉnh tham số, từ đó tìm ra cách phân biệt các lớp khác nhau.

Tập kiểm tra

Tập kiểm tra là tập dữ liệu không dùng trong quá trình huấn luyện mà chỉ dùng để đánh giá mô hình sau khi đã học xong. Mục đích của tập kiểm tra là xem mô hình có dự đoán đúng trên dữ liệu mới hay không.

Nếu mô hình đạt kết quả tốt trên tập huấn luyện nhưng kém trên tập kiểm tra, điều đó cho thấy mô hình có thể đã **học thuộc dữ liệu huấn luyện** mà chưa có khả năng tổng quát hóa tốt.

Ý nghĩa của việc chia dữ liệu

Việc chia dữ liệu thành tập huấn luyện và tập kiểm tra giúp:

- đánh giá khách quan chất lượng mô hình
- kiểm tra khả năng dự đoán trên dữ liệu chưa từng gặp
- phát hiện hiện tượng học quá mức
- so sánh hiệu quả giữa các mô hình khác nhau

Nếu không tách riêng tập kiểm tra, kết quả đánh giá có thể quá lạc quan vì mô hình được kiểm tra trên chính dữ liệu mà nó đã học.

4. Tỷ lệ chia dữ liệu

Trong thực tế, dữ liệu thường được chia theo một số tỷ lệ phổ biến như:

- 80% cho tập huấn luyện, 20% cho tập kiểm tra
- 70% cho tập huấn luyện, 30% cho tập kiểm tra
- 75% cho tập huấn luyện, 25% cho tập kiểm tra

Tỷ lệ nào được chọn phụ thuộc vào kích thước dữ liệu. Nếu dữ liệu lớn, ta có thể dành nhiều dữ liệu hơn cho tập huấn luyện. Nếu dữ liệu nhỏ, cần chia cẩn thận để vẫn đảm bảo đủ dữ liệu cho cả hai tập.

5. Cách đánh giá trên tập kiểm tra

Sau khi huấn luyện mô hình trên tập huấn luyện, ta đưa các mẫu trong tập kiểm tra vào mô hình để dự đoán nhãn.

Sau đó, so sánh nhãn dự đoán với nhãn thực tế để tính các chỉ số đánh giá như:

- Accuracy
- Precision
- Recall
- F1-score

Các chỉ số này cho biết mô hình phân lớp đúng ở mức nào và có cân bằng giữa các lớp hay không.

Các chỉ số đánh giá trong bài toán phân lớp

Gọi:

- TP : True Positive (dự đoán đúng lớp dương)
- TN : True Negative (dự đoán đúng lớp âm)
- FP : False Positive (dự đoán sai, âm thành dương)
- FN : False Negative (dự đoán sai, dương thành âm)

Accuracy (Độ chính xác tổng thể)

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

Ý nghĩa: tỷ lệ dự đoán đúng trên toàn bộ dữ liệu

Precision (Độ chính xác lớp dương)

$$Precision = \frac{TP}{TP + FP}$$

Ý nghĩa: trong các mẫu dự đoán là dương, có bao nhiêu là đúng

Recall (Độ bao phủ lớp dương)

$$Recall = \frac{TP}{TP + FN}$$

Ý nghĩa: trong các mẫu thực sự là dương, mô hình tìm được bao nhiêu

F1-score

$$F1 = \frac{2 \times Precision \times Recall}{Precision + Recall}$$

Có thể viết trực tiếp theo TP, FP, FN:

$$F1 = \frac{2TP}{2TP + FP + FN}$$

Ý nghĩa: trung bình điều hòa giữa Precision và Recall

3. Phân lớp bằng cây quyết định

Cây quyết định là một mô hình phân lớp có cấu trúc giống một cái cây. Mỗi nút trong cây biểu diễn một phép kiểm tra trên một thuộc tính, mỗi nhánh biểu diễn kết quả của phép kiểm tra đó và mỗi lá biểu diễn lớp dự đoán cuối cùng. Quá trình xây dựng cây là quá trình phân chia dữ liệu nhiều lần dựa trên các thuộc tính khác nhau, nhằm làm cho dữ liệu ở mỗi nhánh trở nên “dễ dự đoán” hơn.

Tại mỗi nút, thuật toán cần quyết định:


Nên chọn thuộc tính nào để chia dữ liệu?

Đây là yếu tố quan trọng nhất ảnh hưởng đến chất lượng của cây quyết định.

Để lựa chọn, ta cần một tiêu chí đo lường mức độ “tốt” của việc phân chia. Các tiêu chí này đều dựa trên một ý tưởng chung: “Sau khi chia, dữ liệu phải trở nên ít “không chắc chắn” (uncertainty) hơn.”

Trong đó Entropy là một chỉ số đo mức độ “không chắc chắn” (uncertainty) của dữ liệu.

- Nếu **dễ đoán** kết quả → **Entropy thấp**
- Nếu **khó đoán** kết quả → **Entropy cao**



Công thức Entropy

$$H(S) = - \sum_{i=1}^k p_i \log_2 p_i$$

Trong đó:

- p_i : xác suất của lớp i
- k : số lớp

Mục tiêu khi xây cây quyết định

Mục tiêu cốt lõi khi xây dựng cây quyết định là:

Tìm cách phân chia dữ liệu sao cho mức độ không chắc chắn (Entropy) giảm xuống nhiều nhất sau mỗi lần phân nhánh.

Nói cách khác, quá trình xây cây là quá trình biến đổi:

- Từ trạng thái ban đầu: dữ liệu còn hỗn loạn, khó dự đoán. (Entropy cao)
- Sang trạng thái sau khi chia: dữ liệu trong mỗi nhánh trở nên đồng nhất hơn, từ đó dễ dự đoán hơn. (Entropy thấp)

Ví dụ: Dự đoán bệnh (A/B) dựa trên:

- Symptom (Triệu chứng)
- Gender (Giới tính)

ID	Symptom	Gender	Class
1	Fever	Male	A
2	Fever	Female	A
3	Fever	Male	A
4	Cough	Male	B
5	Cough	Female	B
6	Cough	Male	B
7	Fever	Female	A
8	Cough	Female	B

Phân bố ban đầu

- A: 4
- B: 4

Tỉ lệ: 50–50 → Entropy cao (khó dự đoán)

Giả sử: ta chọn thuộc tính Gender làm thuộc tính phân nhánh:

Với Gender là Male:

ID	Symptom	Gender	Class
1	Fever	Male	A
3	Fever	Male	A
4	Cough	Male	B
6	Cough	Male	B

Tỉ lệ: 50–50 → Entropy vẫn cao

Với Gender là Female:

ID	Symptom	Gender	Class
2	Fever	Female	A
5	Cough	Female	B
7	Fever	Female	A
8	Cough	Female	B

Tỉ lệ: 50–50 → Entropy vẫn cao

Giả sử: ta chọn thuộc tính Symptom làm thuộc tính phân nhánh:

Với Symptom là Fever:

ID	Symptom	Gender	Class
1	Fever	Male	A
2	Fever	Female	A
3	Fever	Male	A
7	Fever	Female	A

Tỉ lệ: 100% class A → **Entropy = 0**

Với Symptom là Cough:

ID	Symptom	Gender	Class
4	Cough	Male	B
5	Cough	Female	B
6	Cough	Male	B
8	Cough	Female	B

Tỉ lệ: 100% class B → **Entropy = 0**

Một số tiêu chí phổ biến:

Information Gain

Information Gain đo: Thuộc tính nào giúp **giảm entropy nhiều nhất**

$$G(S, A) = E(S) - \sum_{i=1}^m f_s(A_i) E(S_{(A_i)})$$

Trong đó:

- $G(S, A)$: độ lợi thông tin của tập S khi phân chia theo thuộc tính A
- $E(S)$: độ bất định (Entropy) của tập S , được tính theo công thức:

$$E(S) = - \sum_{j=1}^n f_s(A_i) \log_2 f_s(A_i)$$

- m : số giá trị khác nhau của thuộc tính A
- A_i : là số mẫu tương ứng với mỗi giá trị i của thuộc tính A
- $f_S(A_i)$: là tỷ lệ của số mẫu có thuộc tính A_i với S
- S_{A_i} : là một tập con của S chứa tất cả các mẫu có giá trị A_i

Gini Index

Một số cây quyết định như CART dùng chỉ số Gini thay cho Entropy.

Gini đo: Khả năng **dự đoán sai** nếu chọn ngẫu nhiên theo phân bố

Gini cao $\rightarrow$ dễ đoán sai

Gini thấp $\rightarrow$ ít sai hơn

Công thức chỉ số Gini của tập huấn luyện S :

$$Gini(S) = 1 - \sum_j p(j | S)^2$$

Với $p(j | S)$ là tần suất của lớp j trong S .

Khi phân chia nút A thành k nhánh, chất lượng của phép chia được tính bằng công thức:

$$Gini_A(S) = \sum_{i=1}^k \frac{n_i}{n} Gini(i)$$

Trong đó:

n_i : là số mẫu trong nút i

n : là số mẫu trong nút A

4. Phân lớp bằng Naive Bayes

Naive Bayes là một mô hình phân lớp dựa trên xác suất. Mô hình này sử dụng định lý Bayes để dự đoán nhãn của một mẫu dữ liệu dựa trên các đặc trưng đầu vào. Ý tưởng chính là tính xác suất một mẫu thuộc về từng lớp và chọn lớp có xác suất cao nhất.

Quá trình phân lớp không dựa trên việc chia dữ liệu như cây quyết định, mà dựa trên việc tính toán xác suất của từng lớp dựa trên dữ liệu đã học.

Tại mỗi mẫu cần dự đoán, thuật toán cần quyết định:

Mẫu dữ liệu này có xác suất thuộc lớp nào cao nhất?

Đây là yếu tố quan trọng nhất ảnh hưởng đến kết quả phân lớp của Naive Bayes.

Để lựa chọn, ta cần tính toán xác suất hậu nghiệm của từng lớp dựa trên dữ liệu đầu vào.

Naive Bayes dựa trên định lý Bayes:

$$P(C | x) = \frac{P(x | C) P(C)}{P(x)}$$

Trong đó:

- $P(C | x)$: xác suất mẫu x thuộc lớp C
- $P(x | C)$: xác suất xuất hiện dữ liệu x khi biết lớp C
- $P(C)$: xác suất của lớp C trong tập dữ liệu
- $P(x)$: hằng số (giống nhau cho mọi lớp)

III. Ví dụ minh họa

Cho bảng dữ liệu về đánh giá rủi ro hồ sơ vay tín dụng tại một ngân hàng như sau:

Thu nhập	Nghề nghiệp	Tình trạng hôn nhân	Sở hữu nhà	Nguy cơ
Thấp	Vận tải	Độc thân	Rồi	Rủi ro cao
Thấp	Vận tải	Độc thân	Chưa	Rủi ro cao
Cao	Vận tải	Độc thân	Rồi	Rủi ro thấp
Trung bình	Truyền thông	Độc thân	Rồi	Rủi ro thấp
Trung bình	Kinh doanh	Đã kết hôn	Rồi	Rủi ro thấp
Trung bình	Kinh doanh	Đã kết hôn	Chưa	Rủi ro cao
Cao	Kinh doanh	Đã kết hôn	Chưa	Rủi ro thấp
Thấp	Truyền thông	Độc thân	Rồi	Rủi ro cao
Thấp	Kinh doanh	Đã kết hôn	Rồi	Rủi ro thấp
Trung bình	Truyền thông	Đã kết hôn	Rồi	Rủi ro thấp
Thấp	Truyền thông	Đã kết hôn	Chưa	Rủi ro thấp
Cao	Truyền thông	Độc thân	Chưa	Rủi ro thấp
Cao	Vận tải	Đã kết hôn	Rồi	Rủi ro thấp
Trung bình	Truyền thông	Độc thân	Chưa	Rủi ro cao
Cao	Kinh doanh	Độc thân	Rồi	Rủi ro cao

In this dataset, the **Risk Level** column is the decision attribute.

1. Cây quyết định Decision Tree

Xây dựng cây quyết định bằng Information Gain

Ban đầu, tập dữ liệu S gồm 15 mẫu, trong đó có 9 mẫu thuộc lớp *Rủi ro thấp* và 6 mẫu thuộc lớp *Rủi ro cao*.

Độ bất định (Entropy) của tập S được tính như sau:

$$E(S) = -\frac{9}{15} \log_2 \frac{9}{15} - \frac{6}{15} \log_2 \frac{6}{15} \approx 0.97$$

Xét thuộc tính Thu nhập

Thuộc tính **Thu nhập** có 3 giá trị: *Thấp*, *Trung bình*, *Cao*.

- Thấp: 5 mẫu (3 cao, 2 thấp)
- Trung bình: 5 mẫu (2 cao, 3 thấp)
- Cao: 5 mẫu (1 cao, 4 thấp)

Ta tính entropy:

$$E(S_{\text{thấp}}) = -\frac{3}{5} \log_2 \frac{3}{5} - \frac{2}{5} \log_2 \frac{2}{5} \approx 0.971$$

$$E(S_{\text{trung bình}}) = -\frac{2}{5} \log_2 \frac{2}{5} - \frac{3}{5} \log_2 \frac{3}{5} \approx 0.971$$

$$E(S_{\text{cao}}) = -\frac{1}{5} \log_2 \frac{1}{5} - \frac{4}{5} \log_2 \frac{4}{5} \approx 0.722$$

Độ lợi thông tin:

$$G(S, \text{Thu nhập}) = 0.97 - \frac{5}{15} \times 0.971 - \frac{5}{15} \times 0.971 - \frac{5}{15} \times 0.722 \approx 0.083$$

Xét thuộc tính Nghề nghiệp

Các giá trị: *Vận tải*, *Truyền thông*, *Kinh doanh*

- Vận tải: 4 mẫu (2 cao, 2 thấp)
- Truyền thông: 6 mẫu (2 cao, 4 thấp)

- Kinh doanh: 5 mẫu (2 cao, 3 thấp)

Entropy:

$$E(S_{\text{vậntải}}) = -\frac{2}{4}\log_2 \frac{2}{4} - \frac{2}{4}\log_2 \frac{2}{4} = 1$$

$$E(S_{\text{truyềnthông}}) = -\frac{2}{6}\log_2 \frac{2}{6} - \frac{4}{6}\log_2 \frac{4}{6} \approx 0.918$$

$$E(S_{\text{kinhdoanh}}) = -\frac{2}{5}\log_2 \frac{2}{5} - \frac{3}{5}\log_2 \frac{3}{5} \approx 0.971$$

Độ lợi thông tin:

$$G(S, \text{Nghề nghiệp}) = 0.97 - \frac{4}{15} \times 1 - \frac{6}{15} \times 0.918 - \frac{5}{15} \times 0.971 \approx 0.013$$

Xét thuộc tính Tình trạng hôn nhân

Giá trị: *Độc thân, Đã kết hôn*

- Độc thân: 8 mẫu (5 cao, 3 thấp)
- Đã kết hôn: 7 mẫu (1 cao, 6 thấp)

Entropy:

$$E(S_{\text{độcthân}}) = -\frac{5}{8}\log_2 \frac{5}{8} - \frac{3}{8}\log_2 \frac{3}{8} \approx 0.954$$

$$E(S_{\text{đãkếthôn}}) = -\frac{1}{7}\log_2 \frac{1}{7} - \frac{6}{7}\log_2 \frac{6}{7} \approx 0.6$$

Độ lợi thông tin:

$$G(S, \text{Tình trạng hôn nhân}) = 0.97 - \frac{8}{15} \times 0.954 - \frac{7}{15} \times 0.6 \approx 0.186$$

Xét thuộc tính Sở hữu nhà

Giá trị: *Chưa, Rồi*

- Chưa: 6 mẫu (3 cao, 3 thấp)
- Rồi: 9 mẫu (3 cao, 6 thấp)

Entropy:

$$E(S_{\text{chưa}}) = -\frac{3}{6}\log_2 \frac{3}{6} - \frac{3}{6}\log_2 \frac{3}{6} = 1$$

$$E(S_{\text{rồi}}) = -\frac{3}{9}\log_2 \frac{3}{9} - \frac{6}{9}\log_2 \frac{6}{9} \approx 0.918$$

Độ lợi thông tin:

$$G(S, \text{Sở hữu nhà}) = 0.97 - \frac{6}{15} \times 1 - \frac{9}{15} \times 0.918 \approx 0.02$$

Trong 4 thuộc tính đã xem xét, Tình trạng hôn nhân có độ lợi thông tin lớn nhất. Do đó, ta chọn thuộc tính này làm phép chia nhánh cho cây tại nút gốc.

Tập dữ liệu lúc này được chia làm hai phần tương ứng với hai nhánh cây theo giá trị của thuộc tính Tình trạng hôn nhân. Phần có giá trị Độc thân gồm 8 dòng, phần có giá trị Đã kết hôn gồm 7 dòng.

Với nhánh cây thứ nhất, nhánh Độc thân, xét thuộc tính Thu nhập, tính toán tương tự ta có:

$$E(S_{\text{thấp}}) = 0; E(S_{\text{trung bình}}) = 1; E(S_{\text{cao}}) \approx 0.92; G(S_{\text{độc thân}}, \text{Thu nhập}) \approx 0.36$$

Với hai thuộc tính Nghề nghiệp và Sở hữu nhà, ta có:

$$E(S_{\text{vận tải}}) \approx 0.92; E(S_{\text{truyền thông}}) = 1; E(S_{\text{kinh doanh}}) = 0;$$

$$G(S_{\text{độc thân}}, \text{Nghề nghiệp}) \approx 0.11$$

$$E(S_{\text{chưa}}) \approx 0.92; E(S_{\text{rồi}}) \approx 0.971; G(S_{\text{độc thân}}, \text{Sở hữu nhà}) \approx 0.003$$

Vậy ở nhánh này ta chọn Thuộc tính Thu nhập làm phép chia nhánh. Với giá trị Thu nhập bằng Thấp, ta luôn có phân lớp Rủi ro cao, vì vậy nhánh này đi đến nút lá và không cần xét tiếp. Hai nhánh con tương ứng với hai giá trị còn lại là Trung bình và Cao sẽ tiếp tục được phát triển.

Nhánh tương ứng với giá trị Cao bao gồm 3 dòng dữ liệu, xét các thuộc tính còn lại ta có:

$$E(S_{\text{vận tải}}) = 0; E(S_{\text{truyền thông}}) = 0; E(S_{\text{kinh doanh}}) = 0;$$

$$G(S_{\text{cao}}, \text{Nghề nghiệp}) \approx 0.92$$

$$E(S_{\text{chưa}}) = 0; E(S_{\text{rồi}}) = 1; G(S_{\text{cao}}, \text{Sở hữu nhà}) \approx 0.252$$

Với giá trị độ lợi thông tin lớn hơn, cây sẽ tiếp tục được phân nhánh bằng thuộc tính Nghề nghiệp. Đến đây, hai nhánh Vận tải và Truyền thông sẽ đi đến nút lá Rủi ro thấp, nhánh Kinh doanh sẽ đi đến nút lá Rủi ro cao.

Nhánh tương ứng với giá trị Trung bình gồm 2 dòng dữ liệu, tiếp tục tính độ lợi thông tin ta có:

$$E(S_{\text{truyềnthông}}) = 1; G(S_{\text{trungbình}}, \text{Nghề nghiệp}) = 0$$

$$E(S_{\text{chưa}}) = 0; E(S_{\text{rời}}) = 0; G(S_{\text{trungbình}}, \text{Sở hữu nhà}) = 1$$

Nhánh này sẽ được phân chia bằng thuộc tính Sở hữu nhà, nhánh con Chưa sẽ đi đến nút lá Rủi ro cao, nhánh con Rồi sẽ đi đến nút lá Rủi ro thấp.

Trở lại với nhánh Đã kết hôn, được phân chia từ nút gốc, ta có 7 dòng dữ liệu. Xét các thuộc tính Thu nhập, Nghề nghiệp và Sở hữu nhà ta được kết quả sau:

$$E(S_{\text{thấp}}) = 0; E(S_{\text{trungbình}}) \approx 0.92; E(S_{\text{cao}}) = 0; G(S_{\text{đãkếthôn}}, \text{Thu nhập}) \approx 0.2$$

$$E(S_{\text{vậntải}}) = 0; E(S_{\text{truyềnthông}}) = 0; E(S_{\text{kinhdoanh}}) \approx 0.811;$$

$$G(S_{\text{đãkếthôn}}, \text{Nghề nghiệp}) \approx 0.128$$

$$E(S_{\text{chưa}}) \approx 0.92; E(S_{\text{rời}}) = 0; G(S_{\text{đãkếthôn}}, \text{Sở hữu nhà}) \approx 0.2$$

Ở nhánh này có hai thuộc tính có độ lợi thông tin cao bằng nhau đó là: Thu nhập và Sở hữu nhà. Ta chọn Thu nhập để tiếp tục, với giá trị Thấp và giá trị Cao, cây sẽ phát triển đến nút lá Rủi ro thấp.


Chúng ta chỉ việc xem xét phát triển cây với giá trị Trung bình, ta có:

$$E(S_{\text{truyềnthông}}) = 0; E(S_{\text{kinhdoanh}}) = 1; G(S_{\text{trungbình}}, \text{Nghề nghiệp}) \approx 0.252$$

$$E(S_{\text{chưa}}) = 0; E(S_{\text{rời}}) = 0; G(S_{\text{trungbình}}, \text{Sở hữu nhà}) \approx 0.92$$

Chọn Sở hữu nhà làm thuộc tính phân nhánh, lúc này với giá trị Chưa ta luôn có Rủi ro cao, với giá trị Rồi ta luôn có Rủi ro thấp, như vậy thuật toán kết thúc.

Kết quả cây quyết định được trình bày trong hình bên dưới:



Xây dựng cây quyết định bằng Gini index

Theo những thông kê từ câu 2, ta tính chỉ số Gini của lần lượt từng thuộc tính để tìm ra thuộc tính phân nhánh có lợi nhất. Xét thuộc tính Thu nhập, ta có:

$$Gini(S_{thấp}) = 1 - \left(\frac{3}{5}\right)^2 - \left(\frac{2}{5}\right)^2 = 0.48$$

$$Gini(S_{trung\ bình}) = 1 - \left(\frac{2}{5}\right)^2 - \left(\frac{3}{5}\right)^2 = 0.48$$

$$Gini(S_{cao}) = 1 - \left(\frac{1}{5}\right)^2 - \left(\frac{4}{5}\right)^2 = 0.32$$

$$Gini_{Thu\ nhập}(S) = \frac{5}{15} \times 0.48 + \frac{5}{15} \times 0.48 + \frac{5}{15} \times 0.32 = 0.427$$

Tiếp tục xét thuộc tính Nghề nghiệp, ta có:

$$Gini(S_{vận\ tải}) = 1 - \left(\frac{2}{4}\right)^2 - \left(\frac{2}{4}\right)^2 = 0.5$$

$$Gini(S_{truyền\ thông}) = 1 - \left(\frac{2}{6}\right)^2 - \left(\frac{4}{6}\right)^2 \approx 0.444$$

$$Gini(S_{kinh\ doanh}) = 1 - \left(\frac{2}{5}\right)^2 - \left(\frac{3}{5}\right)^2 = 0.48$$

$$Gini_{Nghề\ nghiệp}(S) = \frac{4}{15} \times 0.5 + \frac{6}{15} \times 0.444 + \frac{5}{15} \times 0.48 \approx 0.471$$

Với thuộc tính Tình trạng hôn nhân, ta có:

$$Gini(S_{độc\ thân}) = 1 - \left(\frac{5}{8}\right)^2 - \left(\frac{3}{8}\right)^2 \approx 0.469$$

$$Gini(S_{đã\ kết\ hôn}) = 1 - \left(\frac{1}{7}\right)^2 - \left(\frac{6}{7}\right)^2 \approx 0.245$$

$$Gini_{Tình\ trạng\ hôn\ nhân}(S) = \frac{8}{15} \times 0.469 + \frac{7}{15} \times 0.245 \approx 0.403$$

Với thuộc tính Sở hữu nhà, ta có:

$$Gini(S_{chưa}) = 1 - \left(\frac{3}{6}\right)^2 - \left(\frac{3}{6}\right)^2 = 0.5$$

$$Gini(S_{rồi}) = 1 - \left(\frac{3}{9}\right)^2 - \left(\frac{6}{9}\right)^2 \approx 0.444$$

$$Gini_{Sở\ hữu\ nhà}(S) = \frac{6}{15} \times 0.5 + \frac{9}{15} \times 0.444 \approx 0.467$$

Chọn thuộc tính có chỉ số Gini thấp nhất là Tình trạng hôn nhân và phân nhánh theo đó.

Tương tự như trên, khi xét xuống nhánh Độc thân ta tính được giá trị chỉ số Gini như sau:

$$Gini_{Thu\ nhập}(S_{độc\ thân}) = \frac{3}{8} \times 0 + \frac{2}{8} \times 0.5 + \frac{3}{8} \times 0.444 \approx 0.292$$

$$Gini_{Nghề\ nghiệp}(S_{độc\ thân}) = \frac{3}{8} \times 0.444 + \frac{4}{8} \times 0.5 + \frac{1}{8} \times 0 \approx 0.417$$

$$Gini_{Sở\ hữu\ nhà}(S_{độc\ thân}) = \frac{3}{8} \times 0.444 + \frac{5}{8} \times 0.48 \approx 0.467$$

Chọn thuộc tính Thu nhập và tiếp tục phát triển cây, ta tính được các chỉ số Gini sau:

$$Gini_{Nghề\ nghiệp}(S_{cao}) = \frac{1}{3} \times 0 + \frac{1}{3} \times 0 + \frac{1}{3} \times 0 = 0$$

$$Gini_{Sở\ hữu\ nhà}(S_{cao}) = \frac{1}{3} \times 0 + \frac{2}{3} \times 0.5 \approx 0.333$$

Đối với nhánh Cao ta chọn thuộc tính Nghề nghiệp để phân nhánh và đều đi đến các nút lá. Với nhánh Trung bình ta có:

$$Gini_{Nghề nghiệp}(S_{trung bình}) = \frac{2}{2} \times 0.5 = 0.5$$

$$Gini_{Sở hữu nhà}(S_{trung bình}) = \frac{1}{2} \times 0 + \frac{1}{2} \times 0 = 0$$

Ở nhánh này ta chọn thuộc tính Sở hữu nhà làm thuộc tính phân nhánh và cây cũng đi đến các nút lá. Xét tiếp tục nhánh Đã kết hôn ta có:

$$Gini_{Thu nhập}(S_{đã kết hôn}) = \frac{2}{7} \times 0 + \frac{3}{7} \times 0.444 + \frac{2}{7} \times 0.5 \approx 0.19$$

$$Gini_{Nghề nghiệp}(S_{đã kết hôn}) = \frac{1}{7} \times 0 + \frac{2}{7} \times 0 + \frac{4}{7} \times 0.375 \approx 0.214$$


$$Gini_{Sở hữu nhà}(S_{đã kết hôn}) = \frac{3}{7} \times 0.444 + \frac{4}{7} \times 0 \approx 0.19$$

Chỉ số Gini của hai thuộc tính Thu nhập và Sở hữu nhà thấp ngang nhau, ta lựa chọn thuộc tính Sở hữu nhà để chia nhánh. Nhánh với giá trị Rời nổi đến nút lá Rủi ro thấp, xét nhánh Chưa ta có:

$$Gini_{Nghề nghiệp}(S_{chưa}) = \frac{1}{3} \times 0 + \frac{2}{3} \times 0.5 \approx 0.333$$

$$Gini_{Thu nhập}(S_{chưa}) = \frac{1}{3} \times 0 + \frac{1}{2} \times 0 = 0$$

Chọn thuộc tính Thu nhập để tiếp tục phân nhánh, đến đây các nhánh đều đi đến nút lá, kết quả ta thu được cây như sau:



2. Phương pháp Naïve Bayes

Xét lần lượt từng dòng (hồ sơ), dựa theo định lý Bayes để tính xác suất xảy ra của từng Nguy cơ và chọn giá trị xác suất cao nhất.

Hồ sơ 1:

$X = \{\text{Thu nhập} = \text{Trung bình}, \text{Nghề nghiệp} = \text{Vận tải}, \text{Tình trạng hôn nhân} = \text{Độc thân}, \text{Sở hữu nhà} = \text{Rồi}\}$

Ta cần tính được:

$$\begin{aligned} p(\text{Nguy cơ} = \text{Rủi ro cao} \mid X) \\ = \frac{p(X \mid \text{Nguy cơ} = \text{Rủi ro cao}) \cdot p(\text{Nguy cơ} = \text{Rủi ro cao})}{p(X)} \end{aligned}$$

so sánh với

$$\begin{aligned} p(\text{Nguy cơ} = \text{Rủi ro thấp} \mid X) \\ = \frac{p(X \mid \text{Nguy cơ} = \text{Rủi ro thấp}) \cdot p(\text{Nguy cơ} = \text{Rủi ro thấp})}{p(X)} \end{aligned}$$

Vì mẫu số bằng nhau nên chỉ cần so sánh hai tử số.

Áp dụng làm tròn Laplace:

Rủi ro cao:

$$p(\text{Nguy cơ} = \text{Rủi ro cao}) = \frac{6 + 1}{15 + 2} = \frac{7}{17} \approx 0.412$$

$$p(\text{Thu nhập} = \text{Trung bình} \mid \text{Nguy cơ} = \text{Rủi ro cao}) = \frac{2 + 1}{6 + 3} = \frac{1}{3} \approx 0.333$$

$$p(\text{Nghề nghiệp} = \text{Vận tải} \mid \text{Nguy cơ} = \text{Rủi ro cao}) = \frac{2 + 1}{6 + 3} = \frac{1}{3} \approx 0.333$$

$$p(\text{Tình trạng hôn nhân} = \text{Độc thân} \mid \text{Nguy cơ} = \text{Rủi ro cao}) = \frac{5 + 1}{6 + 2} = \frac{3}{4} = 0.75$$

$$p(\text{Sở hữu nhà} = \text{Rồi} \mid \text{Nguy cơ} = \text{Rủi ro cao}) = \frac{3 + 1}{6 + 2} = \frac{1}{2} = 0.5$$

$$\begin{aligned} p(X \mid \text{Nguy cơ} = \text{Rủi ro cao}) \cdot p(\text{Nguy cơ} = \text{Rủi ro cao}) &= \frac{1}{3} \cdot \frac{1}{3} \cdot 0.75 \cdot 0.5 \cdot \frac{7}{17} \\ &\approx 0.017 \end{aligned}$$

Rủi ro thấp:

$$p(\text{Nguy cơ} = \text{Rủi ro thấp}) = \frac{9 + 1}{15 + 2} = \frac{10}{17} \approx 0.588$$

$$p(\text{Thu nhập} = \text{Trung bình} \mid \text{Nguy cơ} = \text{Rủi ro thấp}) = \frac{3 + 1}{9 + 3} = \frac{1}{3} \approx 0.333$$

$$p(\text{Nghề nghiệp} = \text{Vận tải} \mid \text{Nguy cơ} = \text{Rủi ro thấp}) = \frac{2 + 1}{9 + 3} = \frac{1}{4} = 0.25$$

$$p(\text{Tình trạng hôn nhân} = \text{Độc thân} \mid \text{Nguy cơ} = \text{Rủi ro thấp}) = \frac{3 + 1}{9 + 2} = \frac{4}{11} \approx 0.364$$

$$p(\text{Sở hữu nhà} = \text{Rời} \mid \text{Nguy cơ} = \text{Rủi ro thấp}) = \frac{6 + 1}{9 + 2} = \frac{7}{11} \approx 0.636$$

$$p(X \mid \text{Nguy cơ} = \text{Rủi ro thấp}) \cdot p(\text{Nguy cơ} = \text{Rủi ro thấp}) = \frac{1}{3} \cdot 0.25 \cdot \frac{4}{11} \cdot \frac{7}{11} \cdot \frac{10}{17} \approx 0.011$$

Kết luận: hồ sơ thứ nhất thuộc phân lớp **Rủi ro cao**.

Hồ sơ 2:

$X = \{\text{Thu nhập} = \text{Cao}, \text{Nghề nghiệp} = \text{Truyền thông}, \text{Tình trạng hôn nhân} = \text{Độc thân}, \text{Sở hữu nhà} = \text{Rời}\}$

Rủi ro cao:

$$p(\text{Thu nhập} = \text{Cao} \mid \text{Nguy cơ} = \text{Rủi ro cao}) = \frac{1 + 1}{6 + 3} = \frac{2}{9} \approx 0.222$$

$$p(\text{Nghề nghiệp} = \text{Truyền thông} \mid \text{Nguy cơ} = \text{Rủi ro cao}) = \frac{2 + 1}{6 + 3} = \frac{1}{3} \approx 0.333$$

$$p(\text{Tình trạng hôn nhân} = \text{Độc thân} \mid \text{Nguy cơ} = \text{Rủi ro cao}) = \frac{5 + 1}{6 + 2} = \frac{3}{4} = 0.75$$

$$p(\text{Sở hữu nhà} = \text{Rời} \mid \text{Nguy cơ} = \text{Rủi ro cao}) = \frac{3 + 1}{6 + 2} = \frac{1}{2} = 0.5$$

$$p(X \mid \text{Nguy cơ} = \text{Rủi ro cao}) \cdot p(\text{Nguy cơ} = \text{Rủi ro cao}) = \frac{2}{9} \cdot \frac{1}{3} \cdot 0.75 \cdot 0.5 \cdot \frac{7}{17} \approx 0.011$$

Rủi ro thấp:

$$p(\text{Thu nhập} = \text{Cao} \mid \text{Nguy cơ} = \text{Rủi ro thấp}) = \frac{4 + 1}{9 + 3} = \frac{5}{12} \approx 0.417$$

$$p(\text{Nghề nghiệp} = \text{Truyền thông} \mid \text{Nguy cơ} = \text{Rủi ro thấp}) = \frac{4 + 1}{9 + 3} = \frac{5}{12} = 0.417$$

$$p(\text{Tình trạng hôn nhân} = \text{Độc thân} \mid \text{Nguy cơ} = \text{Rủi ro thấp}) = \frac{3 + 1}{9 + 2} = \frac{4}{11} \approx 0.364$$

$$p(\text{Sở hữu nhà} = \text{Rồi} \mid \text{Nguy cơ} = \text{Rủi ro thấp}) = \frac{6+1}{9+2} = \frac{7}{11} \approx 0.636$$

$$p(X \mid \text{Nguy cơ} = \text{Rủi ro thấp}) \cdot p(\text{Nguy cơ} = \text{Rủi ro thấp}) = \frac{5}{12} \cdot \frac{5}{12} \cdot \frac{4}{11} \cdot \frac{7}{11} \cdot \frac{10}{17} \approx 0.024$$

Kết luận: hồ sơ thứ hai thuộc phân lớp **Rủi ro thấp**.

Hồ sơ 3:

$X = \{\text{Thu nhập} = \text{Thấp}, \text{Nghề nghiệp} = \text{Vận tải}, \text{Tình trạng hôn nhân} = \text{Đã kết hôn}, \text{Sở hữu nhà} = \text{Rồi}\}$

Rủi ro cao:

$$p(\text{Thu nhập} = \text{Thấp} \mid \text{Nguy cơ} = \text{Rủi ro cao}) = \frac{3+1}{6+3} = \frac{4}{9} \approx 0.444$$

$$p(\text{Nghề nghiệp} = \text{Vận tải} \mid \text{Nguy cơ} = \text{Rủi ro cao}) = \frac{2+1}{6+3} = \frac{1}{3} \approx 0.333$$

$$p(\text{Tình trạng hôn nhân} = \text{Đã kết hôn} \mid \text{Nguy cơ} = \text{Rủi ro cao}) = \frac{1+1}{6+2} = \frac{1}{4} = 0.25$$

$$p(\text{Sở hữu nhà} = \text{Rồi} \mid \text{Nguy cơ} = \text{Rủi ro cao}) = \frac{3+1}{6+2} = \frac{1}{2} = 0.5$$

$$p(X \mid \text{Nguy cơ} = \text{Rủi ro cao}) \cdot p(\text{Nguy cơ} = \text{Rủi ro cao}) = \frac{4}{9} \cdot \frac{1}{3} \cdot 0.25 \cdot 0.5 \cdot \frac{7}{17} \approx 0.007$$

Rủi ro thấp:

$$p(\text{Thu nhập} = \text{Thấp} \mid \text{Nguy cơ} = \text{Rủi ro thấp}) = \frac{2+1}{9+3} = \frac{1}{4} = 0.25$$

$$p(\text{Nghề nghiệp} = \text{Vận tải} \mid \text{Nguy cơ} = \text{Rủi ro thấp}) = \frac{2+1}{9+3} = \frac{1}{4} = 0.25$$

$$p(\text{Tình trạng hôn nhân} = \text{Đã kết hôn} \mid \text{Nguy cơ} = \text{Rủi ro thấp}) = \frac{6+1}{9+2} = \frac{7}{11} \approx 0.636$$

$$p(\text{Sở hữu nhà} = \text{Rồi} \mid \text{Nguy cơ} = \text{Rủi ro thấp}) = \frac{6+1}{9+2} = \frac{7}{11} \approx 0.636$$

$$p(X \mid \text{Nguy cơ} = \text{Rủi ro thấp}) \cdot p(\text{Nguy cơ} = \text{Rủi ro thấp}) = \frac{1}{4} \cdot \frac{1}{4} \cdot \frac{7}{11} \cdot \frac{7}{11} \cdot \frac{10}{17} \approx 0.014$$

Kết luận: hồ sơ thứ ba thuộc phân lớp **Rủi ro thấp**.

VI. Bài tập

Bài tập 1. Một doanh nghiệp sản xuất đồ chơi cho trẻ em muốn dự đoán doanh số của các sản

phẩm sắp đưa ra thị trường, họ thu thập những dữ liệu dưới đây:

Loại	Số màu	Kích thước	Chất liệu	Doanh số bán
Điều khiển	3	Nhỏ	Nhựa PP	Cao
Xếp hình	5	Vừa	Cao su	Thấp
Xếp hình	7	To	Nhựa PP	Thấp
Điều khiển	5	Nhỏ	Cao su	Thấp
Búp bê	3	Vừa	Nhựa PP	Thấp
Điều khiển	5	Vừa	Nhựa PP	Cao
Búp bê	5	To	Nhựa PP	Cao
Điều khiển	7	Vừa	Cao su	Thấp
Xếp hình	7	To	Cao su	Cao
Xếp hình	3	To	Nhựa PP	Thấp
Búp bê	3	Nhỏ	Cao su	Thấp
Xếp hình	3	Nhỏ	Nhựa PP	Cao
Điều khiển	5	To	Cao su	Thấp
Búp bê	5	Vừa	Nhựa PP	Cao
Búp bê	7	To	Nhựa PP	Cao

Câu 1: Tính giá trị độ lợi thông tin (information gain) của các thuộc tính và vẽ cây quyết định theo thuật toán ID3 cho dữ liệu trên.

Gợi ý:

Tính entropy

def entropy(labels):

from collections *import* Counter

 counter = Counter(labels)

 total = len(labels)

return -sum((c/total)*math.log2(c/total) *for* c *in* counter.values())

Tính information gain

def info_gain(data, attr):

total_entropy = entropy([d["Label"] for d in data])

values = set(d[attr] for d in data)

weighted_entropy = 0

for v in values:

subset = [d for d in data if d[attr] == v]

*weighted_entropy += (len(subset)/len(data)) * entropy([d["Label"] for d in subset])*

return total_entropy - weighted_entropy

Tính IG cho từng thuộc tính

for attr in ["Loai", "Mau", "Size", "ChatLieu"]:

print(attr, info_gain(data, attr))

Vẽ cây

def draw_tree(tree, title="Tree"):

dot = Digraph(comment=title)

dot.attr(rankdir="TB")

dot.attr("node", style="filled", fontname="Arial")

idx = 0

def add_node(subtree, parent=None, edge_label=""):

nonlocal idx

if not isinstance(subtree, dict):

node_id = f"leaf_{idx}"

idx += 1

dot.node(node_id, f"Label = {subtree}", shape="box", fillcolor="lightgreen")

if parent:

dot.edge(parent, node_id, label=str(edge_label))

```
    return

    attr = list(subtree.keys())[0]
    node_id = f"node_{idx}"
    idx += 1

    dot.node(node_id, attr, shape="ellipse", fillcolor="lightblue")

    if parent:
        dot.edge(parent, node_id, label=str(edge_label))

    for val, child in subtree[attr].items():
        add_node(child, node_id, val)

    add_node(tree)

    return dot
```

Câu 2: Tính giá trị chỉ số Gini (gini index) của các thuộc tính và vẽ cây quyết định theo thuật toán CART cho dữ liệu trên.

Gợi ý:

```
def gini(labels):
    from collections import Counter
    counter = Counter(labels)
    total = len(labels)
    return 1 - sum((c/total)**2 for c in counter.values())

def gini_split(data, attr):
    values = set(d[attr] for d in data)
    g = 0
    for v in values:
        subset = [d for d in data if d[attr] == v]
        g += (len(subset)/len(data)) * gini([d["Label"] for d in subset])
    return g

for attr in ["Loai", "Mau", "Size", "ChatLieu"]:
    print(attr, gini_split(data, attr))
```


Câu 3: Sử dụng một trong hai cây quyết định ở trên để tiên đoán giá trị *Doanh số bán* của những sản phẩm sau:

Loại	Số màu	Kích thước	Chất liệu
Búp bê	3	To	Cao su
Xếp hình	5	To	Nhựa PP
Điều khiển	3	Vừa	Cao su

Gợi ý:

```
# Sau khi xây cây → viết hàm predict
def predict(tree, sample):
    if type(tree) != dict:
        return tree
    attr = list(tree.keys())[0]
    value = sample[attr]
    if value in tree[attr]:
        return predict(tree[attr][value], sample)
    else:
        return "Unknown"

# Ví dụ
sample = {"Loai": "Bup be", "Mau": 3, "Size": "To", "ChatLieu": "Cao su"}
print(predict(tree, sample))
```

Câu 4: Doanh số bán trên thực tế của các sản phẩm ở Câu 3 lần lượt là *Thấp, Thấp, Cao*. Hãy lập ma trận nhầm lẫn, sau đó tính giá trị độ chính xác, độ phủ của mô hình/cây đã xây dựng.

Gợi ý:

```
from sklearn.metrics import confusion_matrix, accuracy_score, recall_score

y_true = ["Thap", "Thap", "Cao"]
y_pred = ["...", "...", "..."] # kết quả từ cây
cm = confusion_matrix(y_true, y_pred, labels=["Cao", "Thap"])
print(cm)

acc = accuracy_score(y_true, y_pred)
recall = recall_score(y_true, y_pred, pos_label="Cao")
```

```
print("Accuracy:", acc)
print("Recall:", recall)
```

Câu 5: Xác suất không điều kiện của giá trị ‘Xếp hình’ trong tập dữ liệu là bao nhiêu?

Gợi ý:

```
count = sum(1 for d in data if d["Loai"] == "Xep hình")
prob = count / len(data)
print(prob)
```

Câu 6: Khi doanh số bán là ‘Thấp’, hãy tính xác suất đó là những sản phẩm có chất liệu là ‘Cao su’.

Gợi ý:

```
# P(ChatLieu=Cao su | Label=Thap)

subset = [d for d in data if d["Label"] == "Thap"]
count = sum(1 for d in subset if d["ChatLieu"] == "Cao su")
prob = count / len(subset)
print(prob)
```

Câu 7: Sử dụng thuật toán Naïve Bayes và làm tròn Laplace để dự đoán giá trị Doanh số bán của những sản phẩm trong Câu 3.

Gợi ý:

```
from collections import Counter

# Đếm label
label_counts = Counter(d["Label"] for d in data)
# Laplace smoothing
def prob(attr, value, label):
    subset = [d for d in data if d["Label"] == label]
    count = sum(1 for d in subset if d[attr] == value)
    # Laplace
    k = len(set(d[attr] for d in data))
    return (count + 1) / (len(subset) + k)
# Tính xác suất cho mỗi class
def predict_nb(sample):
    probs = {}
```

```
for label in ["Cao", "Thap"]:  
    p = label_counts[label] / len(data)  
    for attr in sample:  
        p *= prob(attr, sample[attr], label)  
    probs[label] = p  
return max(probs, key=probs.get)
```

Câu 8: Với kết quả thu được và doanh số trên thực tế *Câu 4*, hãy lập ma trận nhầm lẫn, sau đó tính giá trị độ chính xác, độ phủ của thuật toán.

Gợi ý:

```
y_pred_nb = [predict_nb(s) for s in test_samples]  
cm = confusion_matrix(y_true, y_pred_nb, labels=["Cao", "Thap"])  
acc = accuracy_score(y_true, y_pred_nb)  
recall = recall_score(y_true, y_pred_nb, pos_label="Cao")
```

Câu 9: So sánh kết quả từ thuật toán cây quyết định và Naïve Bayes.

Gợi ý:

```
print("Decision Tree Accuracy:", acc_tree)  
print("Naive Bayes Accuracy:", acc_nb)
```

Câu 10: Sản phẩm mới của doanh nghiệp dự định tung ra thị trường có thông tin như sau:

Loại	Số màu	Kích thước	Chất liệu
Xếp hình	7	Nhỏ	Cao su

Hãy sử dụng các mô hình đã xây dựng được để dự đoán Doanh số bán của công ty với sản phẩm này.

Gợi ý:

```
new_sample = {"Loai": "Xep hình", "Mau": 7, "Size": "Nho", "ChatLieu": "Cao su"}  
print("Tree:", predict(tree, new_sample))  
print("Naive Bayes:", predict_nb(new_sample))
```

Bài tập 2. Cho tập dữ liệu Red Wine Quality, gồm các thuộc tính lý – hoá của rượu vang đỏ. Mục tiêu là xây dựng mô hình để dự đoán chất lượng rượu (quality).

Chuyển bài toán thành phân lớp nhị phân:

- $\text{quality} \geq 6 \rightarrow \text{Good (1)}$
- $\text{quality} < 6 \rightarrow \text{Bad (0)}$

Câu 1: Tiền xử lý dữ liệu

1. Đọc dữ liệu từ file CSV
2. Kiểm tra: Missing values, Duplicate samples
3. Chuyển đổi nhãn: `df["label"] = (df["quality"] >= 6).astype(int)`
4. Tách X : các thuộc tính đầu vào và y : nhãn
5. Chia dữ liệu với tỉ lệ: Train/Test = 80/20

Câu 2: Xây dựng mô hình Decision Tree, sử dụng: Gini index.

Thực hiện:

1. Huấn luyện mô hình
2. Dự đoán trên tập test

Đánh giá bằng các chỉ số: Accuracy, Precision, Recall, F1-score

Gợi ý:

```
models["Decision Tree"] = Pipeline([
    ("clf", DecisionTreeClassifier(
        criterion="gini",
        max_depth=4,
        random_state=RANDOM_STATE
    ))
])
```

Câu 3: Sử dụng Gaussian Naive Bayes

Thực hiện:

1. Huấn luyện mô hình
2. Dự đoán trên tập test

Đánh giá bằng các chỉ số: Accuracy, Precision, Recall, F1-score

So sánh các metric đánh giá của hai thuật toán Decision Tree và Naive Bayes.

Gợi ý:

```
models["Naive Bayes"] = Pipeline([
    ("scaler", StandardScaler()),
    ("clf", GaussianNB())
])
```

Câu hỏi:

- Mô hình nào tốt hơn?
- Vì sao có sự khác biệt?

Câu 4: Xây dựng mô hình Random Forest

Thực hiện: Huấn luyện với các tham số khác nhau gồm: `n_estimators` và `max_depth`

Đánh giá bằng các chỉ số: Accuracy, Precision, Recall, F1-score.

Gợi ý:

```
models["Random Forest"] = Pipeline([
    ("clf", RandomForestClassifier(
        n_estimators=200,
        max_depth=8,
        random_state=RANDOM_STATE
    ))
])
```

Câu 5: Xây dựng mô hình XGBoost, Sử dụng K-Fold Cross Validation (k=5 hoặc 10).

Huấn luyện với các tham số: `learning_rate`, `max_depth`, `n_estimators`


Gợi ý:

```
models["XGBoost"] = Pipeline([
    ("clf", XGBClassifier(
        n_estimators=200,
```


```
max_depth=4,  
learning_rate=0.05,  
subsample=0.9,  
colsample_bytree=0.9,  
objective="binary:logistic",  
eval_metric="logloss",  
random_state=RANDOM_STATE  
))  
])
```

Đánh giá bằng các chỉ số: Accuracy, Precision, Recall, F1-score

Sau đó sử dụng K-Fold Cross Validation cho ba mô hình trước đó. Tính Accuracy trung bình, độ lệch chuẩn. Sau đó vẽ cây quyết định.



Cây quyết định minh họa:



Câu 6: Vẽ biểu đồ độ quan trọng thuộc tính

So sánh giữa: Decision Tree, Random Forest, XGBoost

Gợi ý:


`importances = model.feature_importances_`

`idx = np.argsort(importances)[::-1]`

`sorted_features = [feature_names[i] for i in idx]`

`sorted_importances = importances[idx]`

Kết quả minh họa:



Bài tập 3. Cho dữ liệu Heart Disease chứa 14 thuộc tính thu thập ở Cleveland, Mỹ.

Thuộc tính ‘target’ là số nguyên có giá trị 0 (không có sự hiện diện) hoặc 1 (có bệnh tim ở bệnh nhân).

Câu 1: Nhập dữ liệu đầu vào và tiến hành tiền xử lý xóa các dòng dữ liệu trống, sửa tên các cột dữ liệu lại như sau để dễ theo dõi: ‘age’, ‘sex’, ‘chest_pain_type’, ‘resting_blood_pressure’, ‘cholesterol’, ‘fasting_blood_sugar’, ‘rest_ecg’, ‘max_heart_rate_achieved’, ‘exercise_induced_angina’, ‘st_depression’, ‘st_slope’, ‘num_major_vessels’, ‘thalassemia’, ‘target’.

Câu 2, 3, 4, 5, 6: Tương tự các câu của bài tập 2.